

Задача "Модуль безопасности персональных данных" (AlfaGen). Критерии оценивания

1. Общие принципы оценивания

- Жюри оценивает **качество и скорость работы модуля** (идентификация → маскирование → демаскирование), **гибкость настройки** и **качество демо**, а не объём кода.
- Production-готовность не оценивается: решение должно работать как демо-прокси в цепочке `система-потребитель → Модуль → LLM`.
- Критерии *рекомендуют* обращать внимание на ключевые моменты решений участников, но не обязывают следовать жёсткому формату: допускается свободная экспертная оценка в рамках указанного диапазона баллов.
- Критерии проверяются запросами к решению участников по установленному датасету (17 категорий, от персональных данных до данных карт).
- Утечка немаскированных ПДН в LLM-запрос/ответ на демо-сценариях — существенное снижение оценки по всем связанным критериям.

2. Шкала оценивания

Итоговая оценка — сумма баллов (максимум 30).

#	Критерий	Баллы
1	Качество идентификации и маскирования ПДН	0-6
2	Корректность демаскирования	0-3
3	Точность отнесения к ПДН и устойчивость к вариациям написания	0-4
4	Гибкая настройка и расширяемость	0-4
5	Производительность и SLA	0-4
6	Безопасность, логирование и метрики	0-3
7	Расширенные сценарии (доп. возможности)	0-3
8	Качество демо и презентации	0-3

3. Детализация критериев

3.1. Качество идентификации и маскирования ПДН (0-6)

Как проверить быстро: подать на демо 5-10 предложений текста с заведомо вставленными ПДН (ФИО, паспорт, карта, телефон, email, ИНН, адрес, CVV, PIN и т.д.) и сравнить вывод с правилами маскирования из постановки.

- Покрыто максимум типов ПДН из перечня в задании (полнота покрытия — основа балла).
- Маска действительно делает обработанный текст нечитаемым и невозстановливаемым.

- Нет пропусков: ПДН из текста не уходит в LLM в открытом виде.
- Оценка свободная: за близкие к правилам маски (допустимые вариации) балл не снимается, за систематические пропуски целых типов — снижается существенно.

3.2. Корректность демаскирования (0-3)

Как проверить быстро: взять замаскированный текст из п. 3.1 и запросить обратное преобразование.

- Демаскированный текст совпадает с оригиналом, позиции знаков сохранены.
- Демаскирование доступно только авторизованной/настроенной системе (см. п. 3.4).
- Если демаскирование не реализовано — 0, без возможности компенсации другими критериями; реализация через токенизацию/детокенизацию засчитывается наравне с классическим демаскированием.

3.3. Точность отнесения к ПДН и устойчивость к вариациям написания (0-4)

Как проверить быстро: текст с «ловушками» — поэт Александр Пушкин, адрес отделения Банка — плюс один вариант с иным регистром, форматом даты (`мм.дд.гггг` , дата текстом) и разделяющими словами («серия ... номер ...»).

- Ложные срабатывания отсутствуют или минимальны (не является ПДН — не маскируется).
- Определение не зависит от регистра.
- Распознаются вариации: форматы дат, написание даты текстом, разделяющие слова.
- Свободный критерий: жюри вправе оценить общую «умность» эвристики/ML-подхода в рамках диапазона.

3.4. Гибкая настройка и расширяемость (0-4)

Как проверить быстро: если у решения нет ReadMe-файла с описанием и возможностями настроек - данный критерий выставляется в 0 баллов. Для быстрой проверки - использовать Readme-файл решения участников, выбрать функционал для тестирования и использовать его.

- Настройка списка систем-потребителей (вкл/откл обращение в модуль).
- Настройка перечня типов ПДН и самого факта маскирования в зависимости от системы.
- Наличие/отсутствие демаскирования по системе.
- Расширение списка идентифицируемых ПДН без переписывания ядра (конфиг, плагины, справочник).

3.5. Производительность и SLA (0-4)

Как проверить быстро: замер latency на 1–2 запросах во время демо (логи/метрики команды)

- Ориентир: $\text{Latency} \leq 0.5$ с при RPS 1000 — целевой уровень; честная оценка своего latency с подтверждением метриками засчитывается даже без полного нагрузочного теста.

- Обработка крупных текстов (до 100 000 токенов) без падения.
- RPS 2000 при том же latency — повышенный уровень (можно учесть и здесь, и в п. 3.7).
- Если нагрузочное подтверждение отсутствует — балл снижается, но не обнуляется при наличии корректной архитектуры.

3.6. Безопасность, логирование и метрики (0-3)

Как проверить быстро: показать лог одного запроса и экран/выдачу метрик.

- Логирование выявленных типов ПДН по каждому запросу; подробное логирование этапов обработки.
- Метрики Latency / RPS / TPS присутствуют.
- Ограничение круга систем, обращающихся в сервис (allowlist, ключи, mTLS — на уровне демо-подтверждения).
- Нет утечек ключей/реальных ПДН в артефактах сдачи; шифрование хранилища соответствия — по усмотрению жюри.
- Корректная обработка ошибок: понятные ответы при невалидном запросе, деградация при недоступности компонентов.

3.7. Расширенные сценарии (доп. возможности) (0-3)

Свободный критерий. Засчитывается любое из (по 1 баллу за уверенно показанное, максимум 3):

- Токенизация/детокенизация или замена синтетическими данными.
- Настройка вида маскирования/токенизации под систему.
- RPS 2000 при Latency ≤ 0.5 с.
- Идентификация документов, удостоверяющих личность, кроме паспорта РФ.
- Контекстное маскирование: маска только при комбинации типов ПДН (PIN + номер карты), с настраиваемым правилом.

3.8. Качество демо и презентации (0-3)

- Есть короткое объяснение принципа работы и архитектуры (1–2 минуты).
- Есть **схема**: Система-потребитель → Модуль (идентификация → маскирование → LLM → демаскирование) → Потребитель.
- Ответы на вопросы лаконичны, аргументированы, корректны.

4. Обязательные артефакты на сдачу

1. Рабочий **демо-сервис-прокси**, запускаемый по инструкции (README), с точками входа для запросов в LLM и обратно.
2. **Инструкция для жюри по проверке**: как отправить тестовый текст, как получить замаскированный/демаскированный результат, где посмотреть логи и метрики.

3. **Схема архитектуры и настройки:** системы-потребители, конфигурируемые типы ПДН и правила маскирования.
4. Сведения о **производительности** (замеры/нагрузочный тест) и список реализованных **дополнительных возможностей**.
5. Описание ограничений решения и плана развития после хакатона.